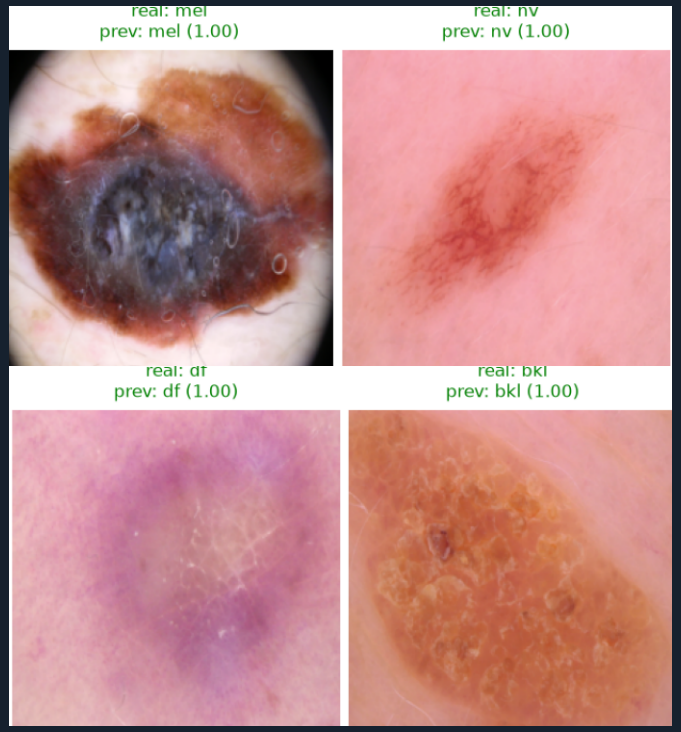


Amostras do conjunto de teste (HAM10000):
mel · nv · df · bkl

Uso educacional — não substitui avaliação clínica.

PROJETO FINAL · VISÃO COMPUTACIONAL · IBMEC BH

Lesões de pele com incerteza

Classificação dermatoscópica em 7 classes com Grad-CAM
e sinalização de casos incertos

CONTEXTO

O melanoma é o câncer de pele mais letal e o diagnóstico precoce muda o prognóstico. A dermatoscopia ajuda, mas a leitura depende da experiência do avaliador. Um modelo de triagem só é útil se acertar as classes raras e graves, e não só a classe majoritária (nevo benigno). Também precisa saber quando não sabe.

PERGUNTA

Uma CNN treinada no HAM10000 consegue classificar as 7 categorias diagnósticas com macro-F1 competitiva e bom recall de melanoma? Ela consegue sinalizar quando está incerta e mostrar, com Grad-CAM, em que região baseou a decisão?

Alice De Muylder Oliveira · Entrega: 12/11/2026

ESCOPO

Tarefa de Visão Computacional

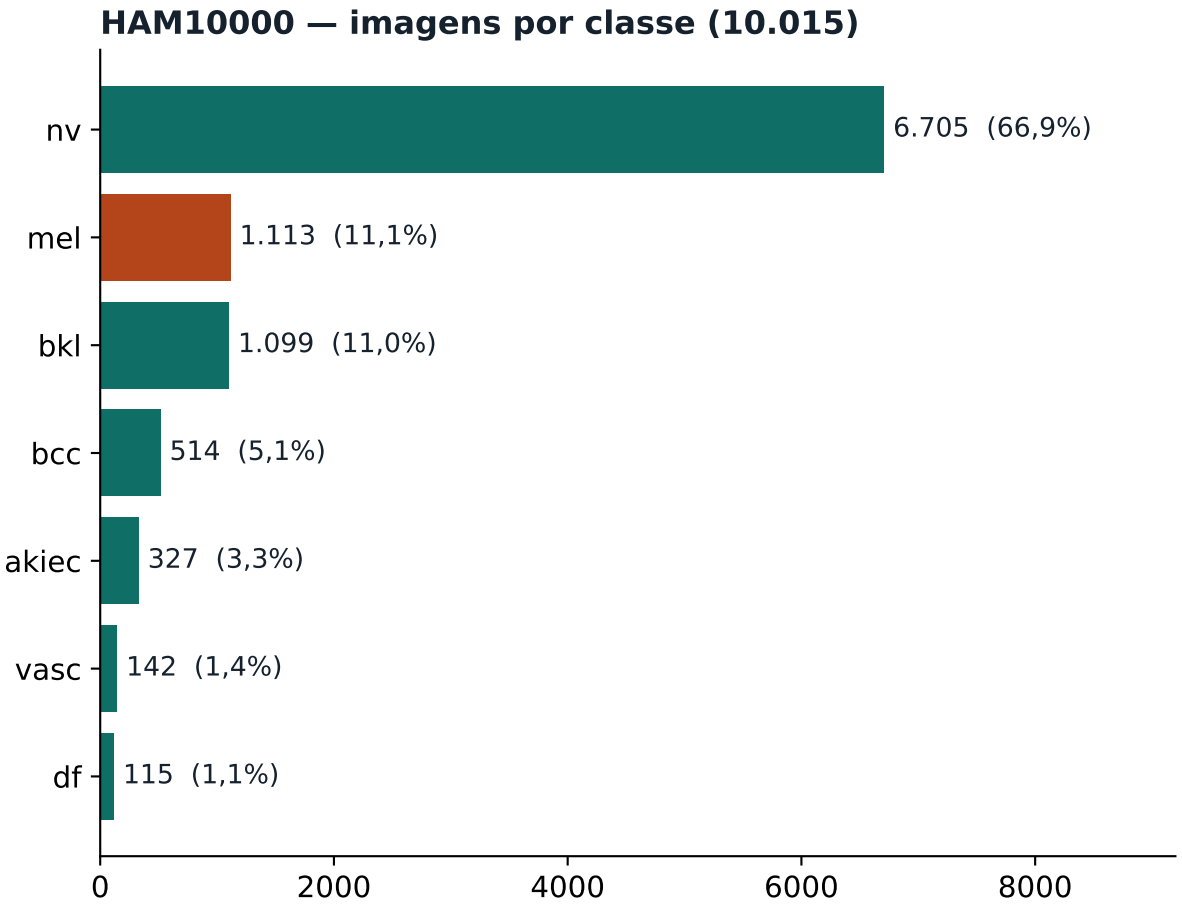
- **Classificação multiclasse (7 classes) — tarefa principal**
  Entrada: imagem dermatoscópica RGB. Saída: 7 logits → softmax → classe prevista e confiança.
- **Incerteza**
  Limiar de confiança definido na VALIDAÇÃO: as 20% menos confiantes são marcadas como "incerto → encaminhar para especialista".
- **Explicabilidade**
  Grad-CAM na última camada convolucional mostra a região que pesou na decisão.
- **Segmentação: fora do escopo (decisão do M2)**
  As 2.594 imagens com máscara (Task 1) e as 10.015 com rótulo (Task 3) não se sobrepõem. O Grad-CAM cumpre o papel de localização qualitativa.

Sigla	Classe	Natureza
akiec	Ceratose actínica / Bowen	pré-maligna
bcc	Carcinoma basocelular	maligna
bkl	Ceratose benigna	benigna
df	Dermatofibroma	benigna
mel	Melanoma	maligna — classe crítica
nv	Nevo melanocítico	benigna — majoritária
vasc	Lesão vascular	benigna

Métrica principal: macro-F1 (pesa todas as classes igualmente).
Métrica crítica: recall de melanoma.

DADOS

Dataset e divisão dos dados



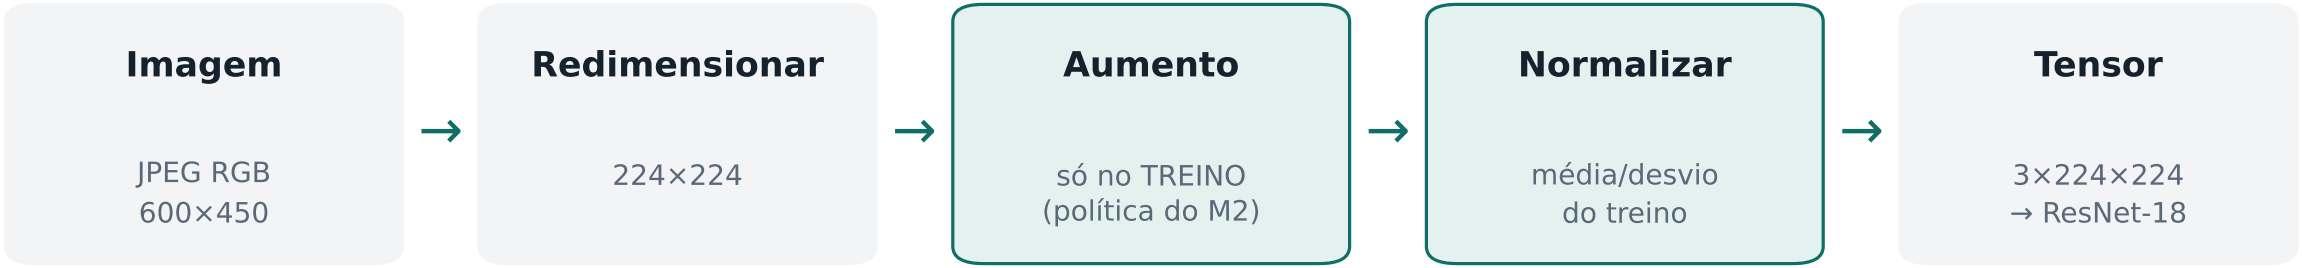
Desbalanceamento de 58:1 entre nv e df: a acurácia sozinha engana.

- **Fonte**
  HAM10000 / ISIC 2018 Task 3 (CC BY-NC 4.0), imagens 600×450.
- **Divisão 70 / 15 / 15**
  Seed 42, manifestos auditados no M2. Teste: 1.493 imagens; treino com cerca de 7 mil.
- **Agrupada por capture_group**
  lesion_id + quase-duplicatas: fotos da mesma lesão ficam no mesmo split.
- **Anti-vazamento**
  2 duplicatas exatas removidas. A checagem de interseção entre splits roda a cada execução. Checkpoint e limiar escolhidos só na validação. Teste usado uma única vez.

Teste	nv	mel	bkl	bcc	akiec	vasc	df
n	995	187	152	68	63	21	7

PRÉ-PROCESSAMENTO

Pipeline de preparação



- **Normalização calculada SOMENTE com imagens de treino**
  média = (0,766; 0,556; 0,580) · desvio = (0,138; 0,152; 0,169). Usar estatísticas do conjunto todo vazaria informação.
- **Aumentos apenas no treino**
  Validação e teste passam só por redimensionamento e normalização, para que as métricas meçam imagens reais.
- **Mesmo pipeline na inferência**
  predict.py aplica a mesma transformação de validação a qualquer imagem nova (demonstração no slide 12).

REFERÊNCIA

Arquitetura e baseline (B0)

Item	Configuração
Arquitetura	ResNet-18 pré-treinada no ImageNet (torchvision), 11,2 M parâmetros
Entrada → saída	3×224×224 → 7 logits (cabeça nova: Dropout 0,2 + Linear 512→7)
Função de perda	CrossEntropy (sem ponderação)
Otimizador	AdamW, weight decay 1e-4
Taxa de aprendizagem	1e-4 com agendamento cosseno
Tamanho do batch	32
Épocas	até 15, com early stopping (paciência 5) na macro-F1 de validação
Regularização	Dropout 0,2 · weight decay · data augmentation · early stopping
Seleção do checkpoint	maior macro-F1 de VALIDAÇÃO
Infra	GPU, precisão mista (AMP) · cerca de 8 min por experimento

Macro-F1 (validação)

0,708

Recall de melanoma (validação)

0,526

Acurácia (validação)

0,850

CADA UM MUDA UMA ÚNICA COISA EM RELAÇÃO AO B0

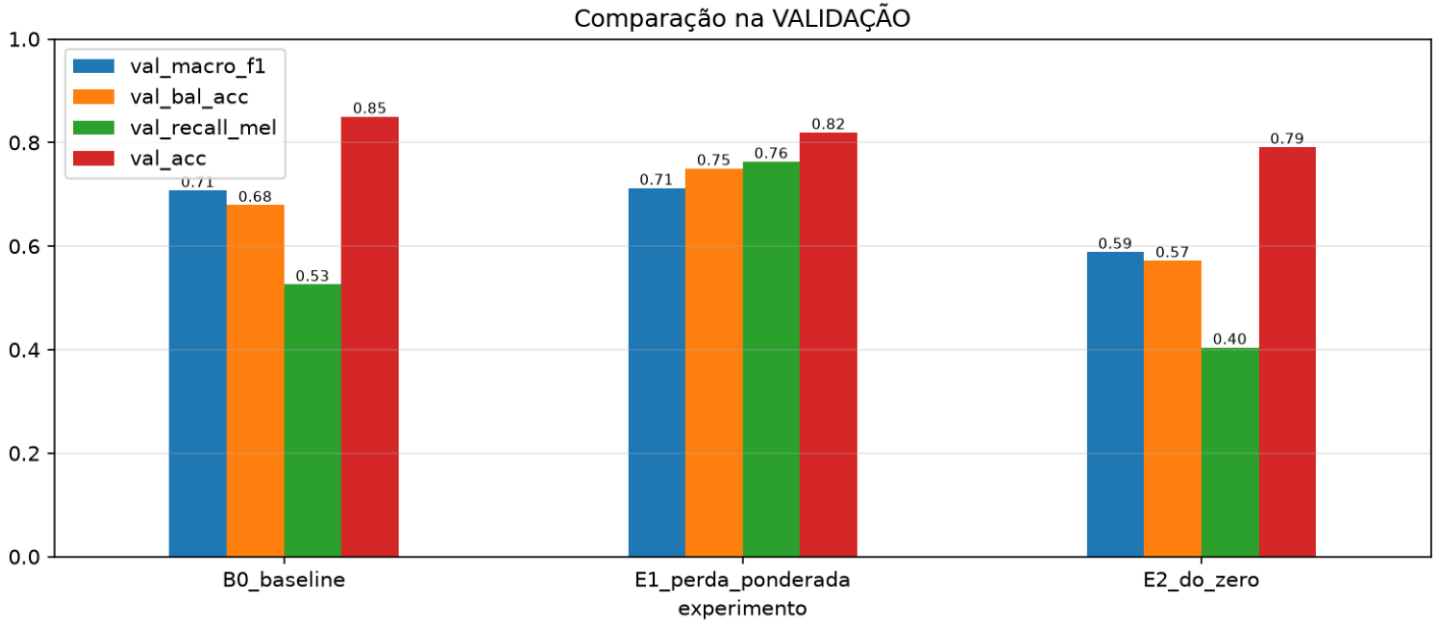
Experimentos controlados

Experimento	O que mudou	Hipótese	Resultado (validação)	Conclusão / decisão
E1 — perda ponderada	CrossEntropy ponderada n / (K·n_c), pesos do treino	Aumenta macro-F1 e recall de mel/df/vasc, com custo em nv	Recall mel 0,53 → 0,76 (+0,24) Bal. acc 0,68 → 0,75 · macro-F1 +0,005 Acurácia 0,85 → 0,82	Hipótese confirmada para recall e bal. acc; macro-F1 praticamente empatada. → MODELO FINAL
E2 — do zero	Sem pesos ImageNet (inicialização aleatória)	Com ~7 mil imagens, a transferência de aprendizado é essencial	Macro-F1 0,71 → 0,59 (-0,12) Recall mel 0,53 → 0,40 · recall df 0,11	Hipótese confirmada. Descartado: perde em todas as métricas.

Critério de escolha (definido antes, aplicado só na validação): maior macro-F1, com desempate pelo recall de melanoma. E1 e B0 empatam na macro-F1 (diferença de 0,005). O E1 ganha por 24 pontos no recall de melanoma e por 7 na acurácia balanceada. Errar um melanoma custa mais que um falso alarme, então a perda de 3 pontos de acurácia (menos acertos em nv) é aceitável.

EXPERIMENTOS

Comparação dos resultados (validação)

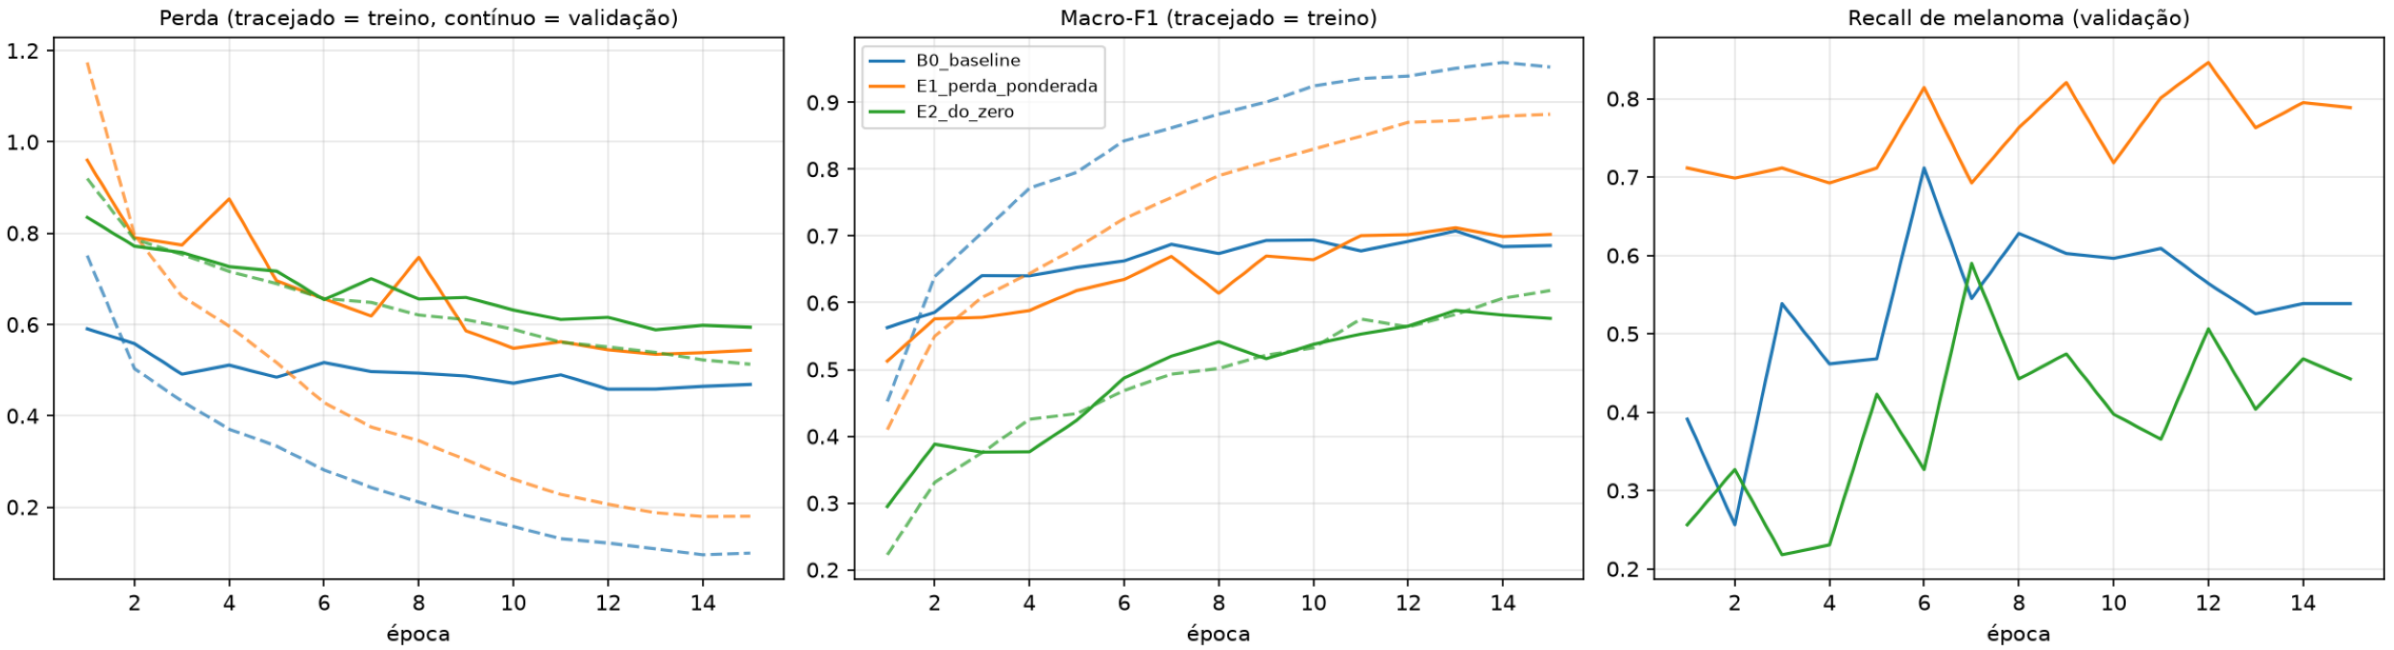


Run	mF1	BalAc	Rec mel	Prec mel	Acc
B0	0,708	0,679	0,526	0,636	0,850
E1	0,712	0,750	0,763	0,551	0,820
E2	0,589	0,572	0,404	0,573	0,791

- Transferência de aprendizado é o fator mais importante: −0,12 de macro-F1 sem ImageNet.
- A ponderação troca precisão por recall: recall de mel +0,24, precisão de mel −0,08.
- A acurácia é a métrica que mais engana: o B0 tem a maior acurácia e o pior recall de melanoma.

EXPERIMENTOS

Curvas de treinamento e validação

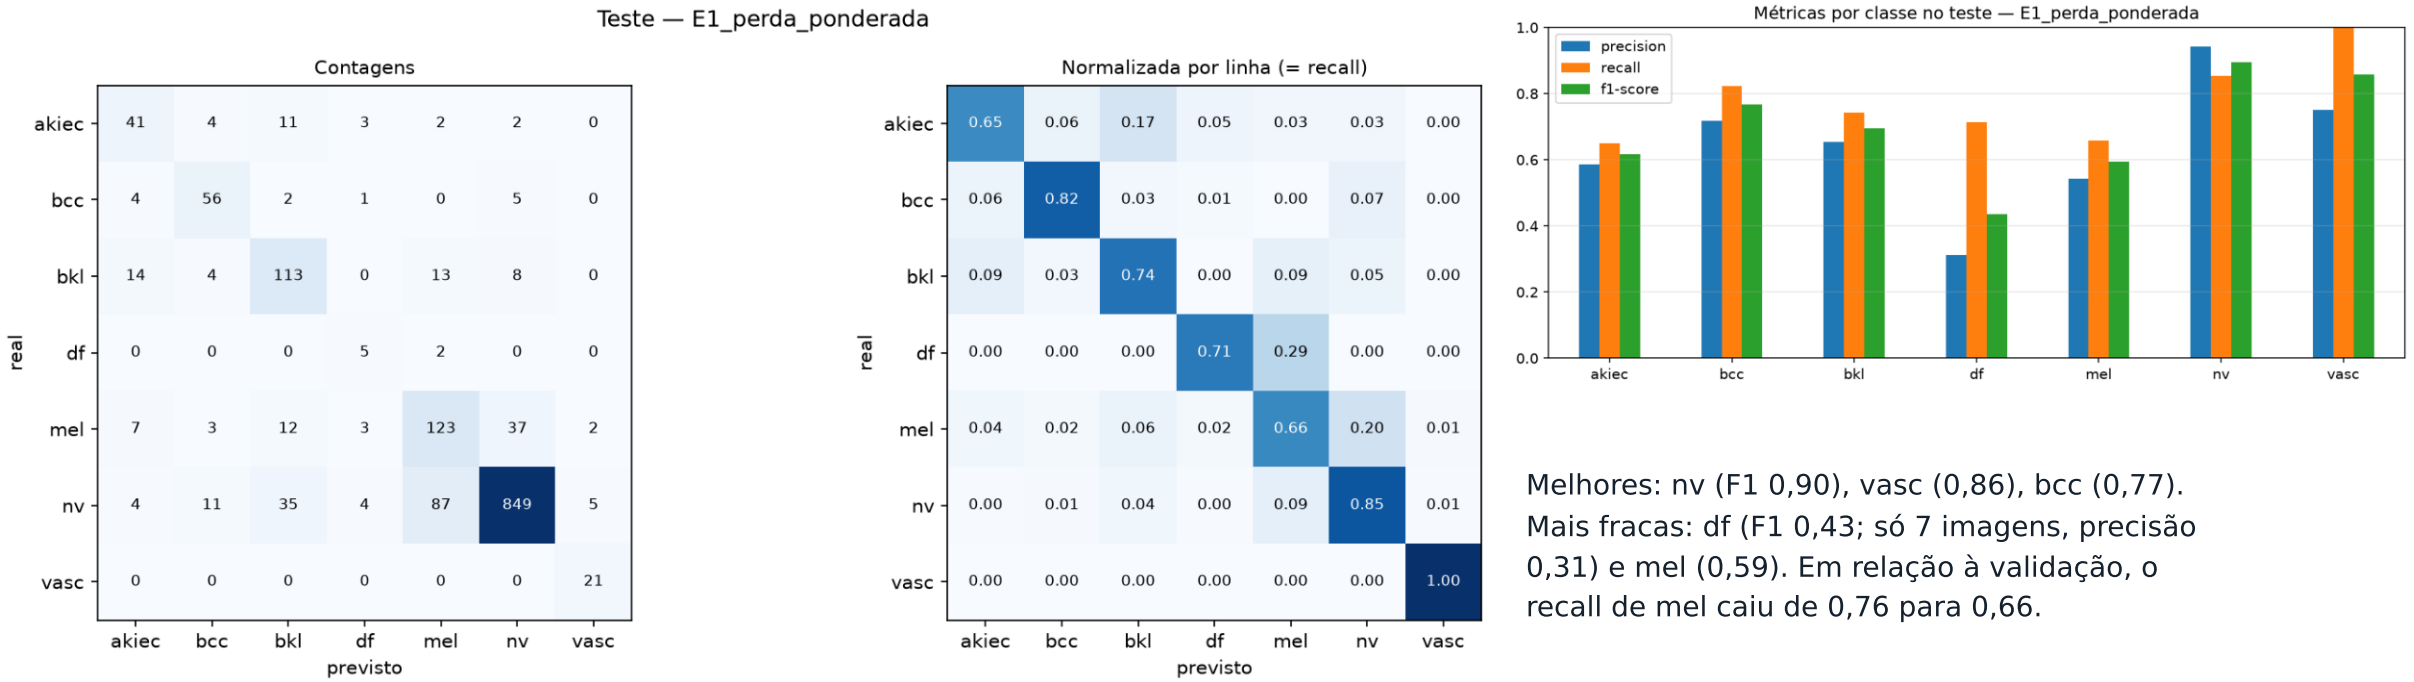


- **B0 (azul) — sobreajuste:**
  a perda de treino cai até cerca de 0,1, enquanto a de validação estaciona em 0,47. A macro-F1 de treino chega a 0,95 contra 0,69 na validação.
- **E1 (laranja):**
  a lacuna é menor e a perda de validação, mais ruidosa. O recall de melanoma fica acima do B0 em todas as épocas (0,7 a 0,85).
- **E2 (verde) — subajuste:**
  treino e validação andam juntos, mas em patamar baixo. Precisaria de muito mais dados ou épocas.
- **Melhor época = 13 de 15 nos três runs:**
  o early stopping não chegou a disparar. Ainda há espaço para testar mais épocas com regularização mais forte.

AVALIAÇÃO ÚNICA · 1.493 IMAGENS NUNCA VISTAS

Modelo final no TESTE — E1 (ResNet-18 + perda ponderada)

Macro-F1	Acurácia balanceada	Recall de melanoma	Acurácia
0,694	**0,778**	**0,658**	**0,809**
trivial (sempre nv): 0,11	média dos recalls	123 de 187 · precisão 0,54	trivial: 0,67

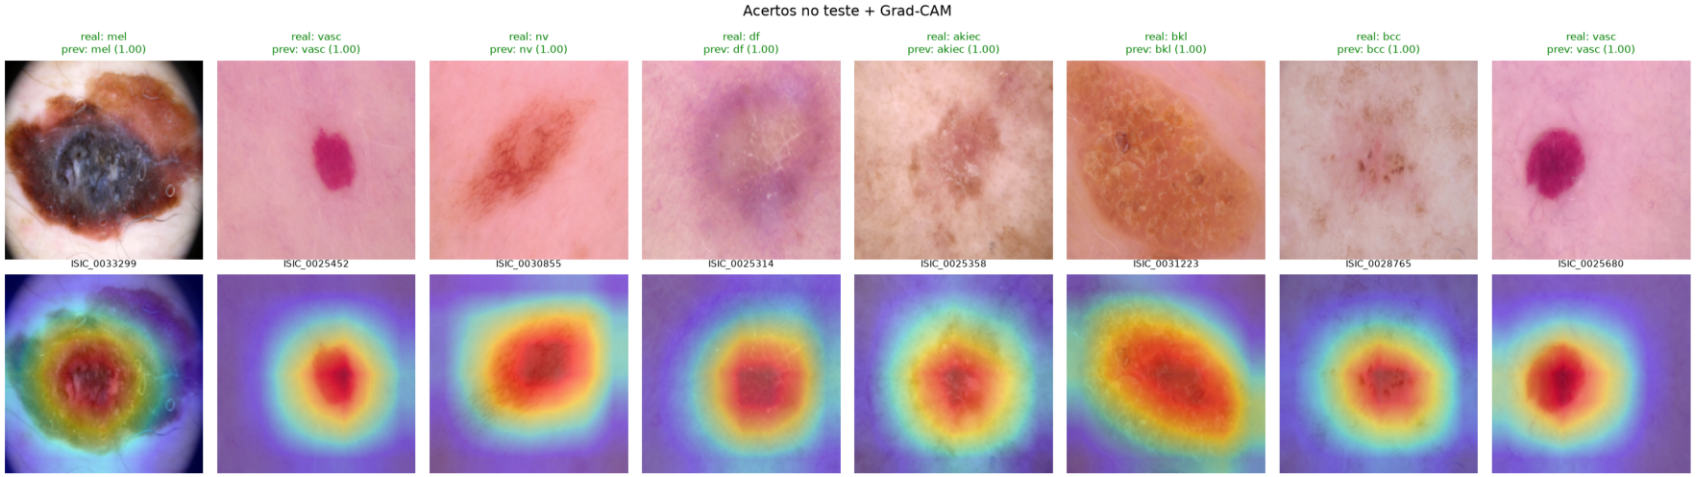


Melhores: nv (F1 0,90), vasc (0,86), bcc (0,77). Mais fracas: df (F1 0,43; só 7 imagens, precisão 0,31) e mel (0,59). Em relação à validação, o recall de mel caiu de 0,76 para 0,66.

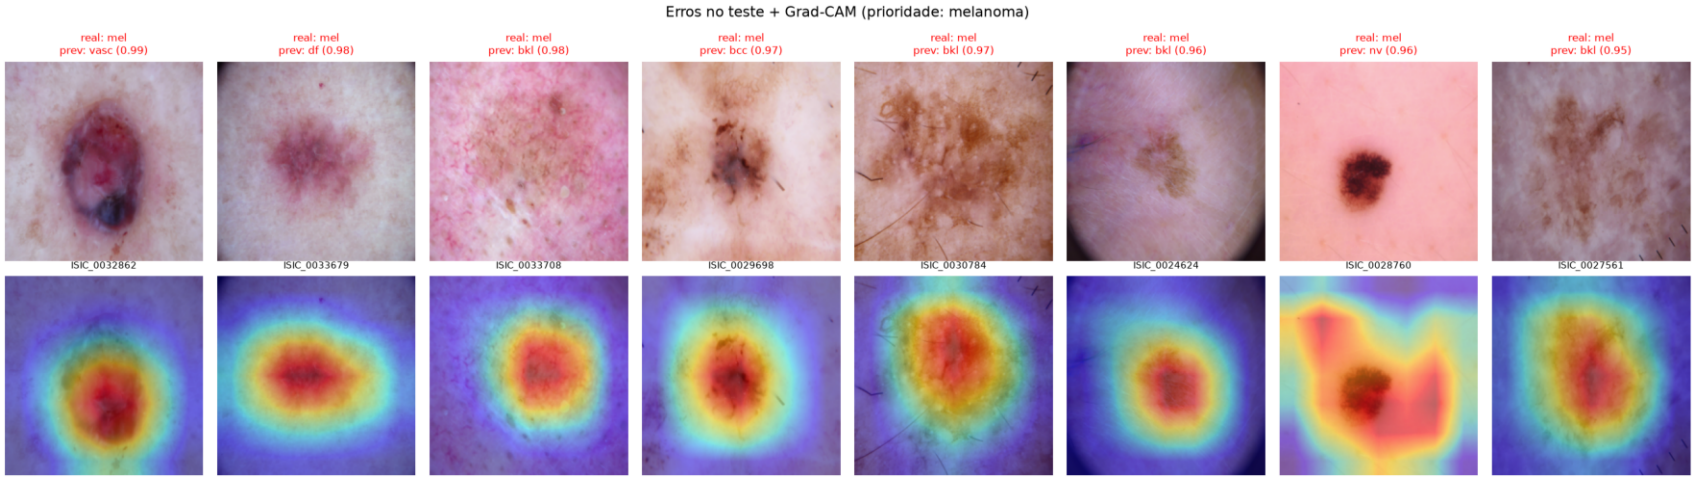
TESTE

Exemplos de acertos e erros (Grad-CAM)

ACERTOS — o mapa se concentra na lesão nas 7 classes.

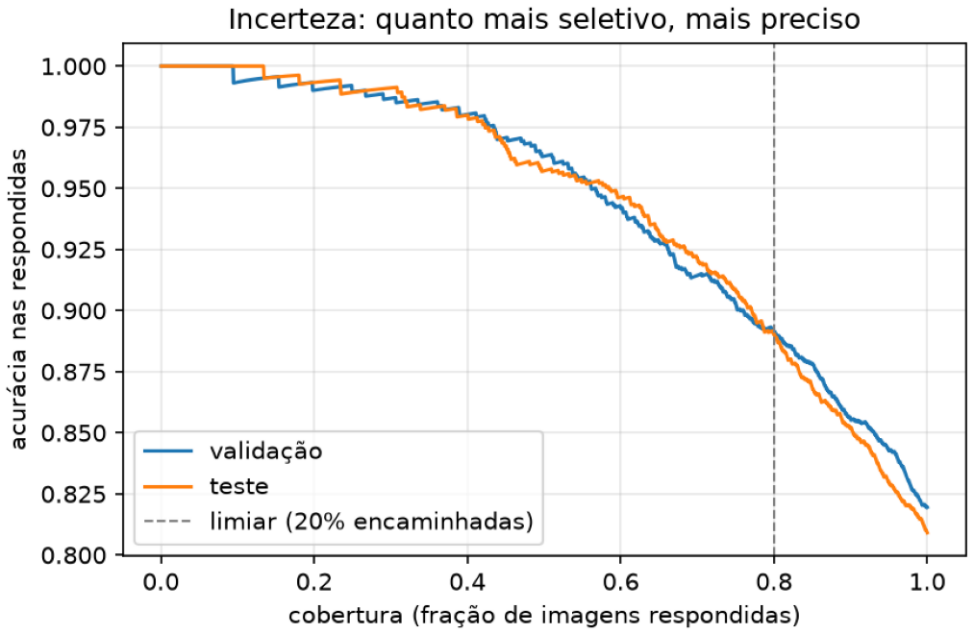


ERROS — os 8 melanomas perdidos com maior confiança (pior tipo de erro).



POR QUE O MODELO ERRA

Análise dos erros e da incerteza



Real	Previsto	n
nv	mel	87
mel	nv	37
nv	bkl	35
bkl	akiec	14
bkl	mel	13
mel	bkl	12

- **nv ↔ mel domina:**
  124 dos 285 erros. As lesões pigmentadas são visualmente parecidas, e a ponderação empurra casos de nv para mel (87 falsos alarmes).
- **bkl ↔ akiec ↔ mel:**
  lesões com textura queratótica parecida.
- **A incerteza ajuda:**
  dos 64 melanomas perdidos, 35 foram marcados como incertos. Melanoma pego ou encaminhado: 84% (contra 66% sozinho).
- **Erros confiantes:**
  45 dos 285 erros têm confiança ≥ 0,9. Esses o limiar não pega (ex.: mel → vasc com 0,99).

AUROC erro
0,84
conf. → erro

Acc confiantes
89%
80% das img.

Acc incertas
48%
20% encaminh.

Acurácia por brilho (atalho do M2)

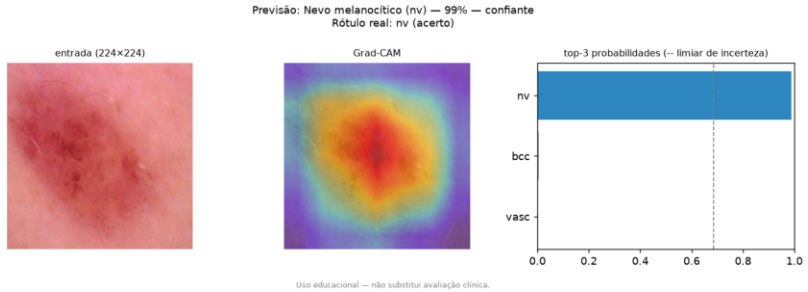


Imagens mais escuras erram mais (78,6% contra 82,8%). O efeito é pequeno, mas indica algum uso de iluminação e captura em vez da lesão.

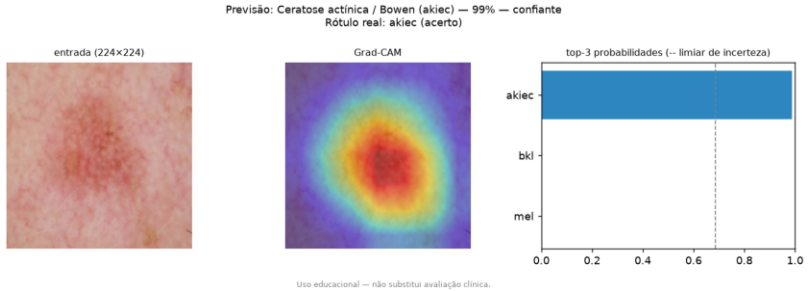
IMAGEM → PRÉ-PROCESSAMENTO → MODELO → RESULTADO

Demonstração do fluxo completo

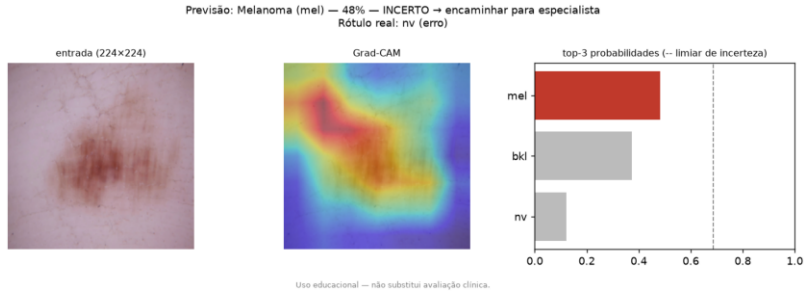
Acerto confiante



Acerto em classe minoritária



Erro sinalizado como INCERTO → encaminhado



Como rodar

```
python predict.py --from-test 6
python predict.py imagem.jpg
```

As imagens vêm do conjunto de TESTE, nunca vistas no treino.

Fluxo: leitura → redimensionar para 224 + normalizar → ResNet-18 E1 → softmax, top-3, Grad-CAM → comparação com o limiar de incerteza (0,686, escolhido na validação).

No 3º exemplo, um nevo foi previsto como melanoma com só 48% de confiança. O sistema não afirma o diagnóstico e encaminha o caso, que é o comportamento desejado.

FECHAMENTO

Conclusão e limitações

RESPOSTA À PERGUNTA

Em parte, sim. A ResNet-18 com perda ponderada chegou a macro-F1 0,69 e acurácia balanceada 0,78 no teste, contra 0,11 de um classificador trivial. A confiança separa bem acertos de erros (AUROC 0,84). O Grad-CAM mostra foco na lesão. O recall de melanoma (0,66) ainda é insuficiente sozinho e sobe para 0,84 quando se contam os casos encaminhados.

RESULTADOS SATISFATÓRIOS?

Sim, como projeto acadêmico de triagem: o modelo supera o baseline no que importa e sabe quando hesitar. Não para uso clínico: 29 melanomas (16%) passaram como confiantes e errados.

O QUE OS EXPERIMENTOS ENSINARAM

- Transferência de aprendizado é indispensável com cerca de 7 mil imagens (E2: −0,12 de macro-F1).
- Com classes desbalanceadas, a acurácia esconde o problema. A ponderação trocou 3 pontos de acurácia por 24 pontos de recall de melanoma.
- O teste confirmou a validação, mas o recall de mel caiu 10 pontos: as estimativas por classe são instáveis.

LIMITAÇÕES

- df com só 7 imagens no teste: métricas de classe pouco confiáveis.
- Erros confiantes (≥ 0,9) escapam do limiar de confiança.
- Sub-representação de peles escuras no HAM10000.
- Leve dependência de brilho e captura (atalho do M2).
- Sem segmentação treinada; um único split e uma única seed.

EVOLUÇÕES

- Calibração (temperature scaling) e MC Dropout ou ensembles para a incerteza.
- Ajuste do limiar de decisão de mel; focal loss; EfficientNet (E3).
- Validação cruzada agrupada e dados externos (ISIC 2019+, Fitzpatrick17k).

Uso educacional — não substitui avaliação clínica.